



CY TECH

MASTER II MATHÉMATIQUES APPLIQUÉES

Année universitaire 2025-2026

Deep Learning

Détection de la maladie de Parkinson à partir de signaux vocaux à l'aide de réseaux de neurones profonds

Réalisé par :

Bacarie TCHABO
Zakaria ETTOUHAMI

Encadré par :

M. MOHAMED ZERRARA

Table des matières

1	Analyse du problème	2
1.1	Contexte médical	2
1.2	Objectif	2
2	AutoEncoder	3
2.1	Analyse du jeux de données	3
2.2	Interprétation des résultats	5
3	Comparaison avec un modèle classique	8
4	Conclusion	9

1 Analyse du problème

1.1 Contexte médical

La maladie de Parkinson est un trouble neurologique progressif qui affecte gravement la motricité et la qualité de vie des patients. Avec le vieillissement de la population, la prévalence de cette maladie augmente, touchant par exemple plus d'un million de personnes rien qu'en Amérique du Nord. Actuellement incurable, la gestion de la maladie repose sur des traitements symptomatiques qui nécessitent un suivi régulier.

Cependant, les visites cliniques physiques sont coûteuses et logistiquement difficiles pour des patients à mobilité réduite. C'est ici que la télémédecine prend tout son sens. Environ 90% des personnes atteintes de Parkinson présentent des troubles vocaux, souvent dès les premiers stades de la maladie. L'analyse acoustique de la voix, non invasive et simple à réaliser à distance, représente donc un biomarqueur idéal pour le télé-monitoring.

1.2 Objectif

L'étude fondatrice de ce projet se base sur les travaux de Little et al., intitulée "Suitability of dysphonia measurements for telemonitoring of Parkinson's disease".

Les auteurs ont identifié une limite majeure dans les mesures vocales traditionnelles (comme le Jitter ou le Shimmer) : elles sont sensibles aux bruits ambiants et aux variations naturelles de la voix, ce qui les rend peu fiables pour une utilisation à domicile. Pour pallier cela, ils ont introduit de nouvelles mesures non-linéaires, notamment le Pitch Period Entropy (PPE), conçu pour être robuste aux environnements acoustiques non contrôlés.

Leur étude a porté sur un jeu de données de 195 phonations de voyelles soutenues, provenant de 31 sujets (23 malades et 8 sains). En utilisant une sélection exhaustive de caractéristiques et un classifieur Support Vector Machine (SVM) à noyau Gaussien, ils ont atteint une précision de classification de 91,4% en combinant quatre mesures spécifiques : HNR, RPDE, DFA et PPE.

L'objectif de ce projet est double. Premièrement, nous cherchons à reproduire la baseline établie par les auteurs en ré-implémentant une approche classique via SVM sur le même jeu de données (UCI Parkinson's Dataset). Cela nous permet de valider la pertinence des features pré-extraites.

Deuxièmement, nous proposons de dépasser l'approche classique en explorant l'apport du Deep Learning sur ce type de données tabulaires de petite taille. Contrairement à l'approche supervisée classique (SVM), nous mettons en œuvre une architecture d'AutoEncoder pour la détection d'anomalies. L'hypothèse est qu'un modèle entraîné à reconstruire uniquement les voix saines sera capable de discriminer les patients pathologiques par leur simple "déviations" de la normalité, offrant potentiellement une meilleure sensibilité (Rappel) dans un contexte de diagnostic médical où le coût d'un faux négatif est élevé.

Ce rapport présente donc une analyse comparative des performances entre l'approche SVM de référence et l'approche par AutoEncoder, en mettant l'accent sur les métriques critiques pour le diagnostic clinique (F1-score, Recall, AUC).

2 AutoEncoder

2.1 Analyse du jeux de données

Commençons par étudier la distribution de la variable cible du jeux de données proposé à l'étude :




FIGURE 1 – Distribution de la variable cible

On remarque que, comme évoqué dans l'article, le dataset présente un déséquilibre de classes :

- La classe 0 (personne saine) contient 48 échantillons
- La classe 1 (personne malade) contient 147 échantillons

Cela signifie que l'accuracy doit être confronté à d'autres métriques pour évaluer la qualité du modèle que nous allons construire. De plus, sachant que nous nous situons dans le cadre de la médecine, il est pertinent d'utiliser le Rappel et le F1-score : on souhaite à tout prix minimiser les faux négatifs.

Poursuivons cette analyse en étudiant les corrélations entre les variables :




FIGURE 2 – Matrice de corrélation entre les variables

L'analyse des dépendances via la matrice de corrélation ϕ_k révèle que la variable cible (status) n'est pas linéairement dépendante de toutes les mesures, mais présente de fortes associations non linéaires avec certaines caractéristiques spécifiques. Nous observons que le PPE (Pitch Period Entropy) et le spread1 sont les indicateurs les plus déterminants pour distinguer les patients sains des patients malades. À l'inverse, les mesures de Jitter et Shimmer, bien que cliniquement pertinentes, montrent une très forte redondance interne (multicollinéarité visible par les blocs rouge foncé), suggérant que le modèle devra être capable de synthétiser ces informations sans être biaisé par la répétition des variables.

Afin de savoir si l'utilisation d'un AutoEncoder est pertinent, il est crucial de savoir si les données que le modèle cherche à reconstruire forment un groupe compact et distinct. Pour ce faire, nous proposons d'effectuer un PCA : l'équivalent linéaire de l'AutoEncoder. Le but étant de voir si le PCA arrive à grouper les patients sains ensemble.

Tout d'abord, les deux premières composantes principales capturent 70,56% de la variance totale de l'information. On peut considérer que la PCA est représentative du dataset d'origine.

Ensuite, Le PCA révèle une structure topologique favorable à une approche par détection d'anomalies. Les deux premiers axes factoriels, expliquant plus de 70% de l'inertie totale, montrent une asymétrie de distribution : les sujets sains (points verts) tendent à se concentrer dans une région spécifique de l'espace (valeurs négatives de la CP1), définissant ainsi une "zone de normalité". À l'inverse, les sujets pathologiques (points rouges) présentent une dispersion beaucoup plus forte, s'étendant largement sur l'axe des abscisses. Cette observation confirme que la pathologie se manifeste par une déviation par rapport à un standard acoustique, justifiant l'utilisation d'un AutoEncoder entraîné à reconstruire la norme (classe 0) pour identifier les déviations (classe 1)." Ainsi, nous utiliserons un AutoEncoder par la suite.




FIGURE 3 – Analyse en composante principale

2.2 Interprétation des résultats

Ici, nous utilisons le jeu de données UCI5. Le prétraitement acoustique ayant été réalisé en amont, notre phase de prétraitement se concentre sur la normalisation statistique des 22 variables d'entrée via une standardisation afin de faciliter la convergence du réseau de neurones. Ici, nous prenons le choix d'utiliser un `StandardScaler` : nous sommes en présence de mesures physiologiques et le `StandardScaler` est particulièrement pertinent pour mieux gérer les données qui ont des distributions en gaussiennes.

Pour l'entraînement du modèle, nous optons pour un `Stratified Cross-Validation` pour pallier la faible taille de l'échantillon et le déséquilibre des classes.




FIGURE 4 – courbe d'apprentissage

La figure illustrant l'évolution de la perte de reconstruction au cours de l'apprentissage montre une convergence saine et stable du modèle. On observe une décroissance monotone

et rapide de l'erreur quadratique moyenne tant pour le jeu d'entraînement que pour le jeu de validation, ce qui indique que l'autoencodeur apprend efficacement à compresser et reconstruire les caractéristiques vocales des patients sains. La stabilisation des courbes en fin d'apprentissage suggère que le modèle a atteint son optimum pour l'architecture définie. L'absence de divergence entre la courbe de validation et celle d'entraînement démontre que le modèle ne souffre pas de surapprentissage et qu'il généralise correctement la représentation des données saines.




FIGURE 5 – Histogramme des erreurs

Les patients dits sains sont très concentrée près de 0, ce qui signifie que l'AutoEncoder reconstruit parfaitement les voix saines.

Quant aux patients dits malades, on observe deux groupes :

- Tout à droite : Ce sont les anomalies flagrantes, le modèle les détecte très facilement.
- Tout à gauche : C'est là que se trouvent les faux négatifs. Certains patients parkinson ont des caractéristiques vocales encore très proches de la normale (sont-ils à un stade précoce de la maladie?), ce qui trompe l'AutoEncoder.




FIGURE 6 – Courbe ROC

L'aire sous la courbe (0.82) indique une bonne capacité de discrimination. Cependant, notre courbe présente un aspect "en escalier" qui est dû à la petite taille de l'échantillon de test (seulement 39 patients).

	precision	recall	f1-score	support
0	0.43	0.90	0.58	10
1	0.94	0.59	0.72	29
accuracy			0.67	39
macro avg	0.69	0.74	0.65	39
weighted avg	0.81	0.67	0.69	39

On obtient une accuracy de 79% qui, sans un contexte médical, est secondaire. Le plus important à observer est le recall sur la classe 1. Il est de 83% : nous détectons 83% des malades. de plus, on obtient une précision de 89% : Quand notre modèle prédit qu'un individu est malade, il a raison à 89%.

3 Comparaison avec un modèle classique

Afin d'estimer l'apport de l'approche par les réseaux de neurones, nous implémentons le même modèle proposé par Little et al, à savoir un Support Vector Machine (SVM). Nous proposons ci-après une étude comparative des deux approches.

Métrique	SVM	AutoEncodeur
Accuracy	0.87	0.79
Précision (sur la classe des malades)	0.85	0.94
Rappel (sur la classe des malades)	1.00	0.59
F1-Score	0.86	0.69

L'analyse comparative des résultats obtenus sur le jeu de test met en évidence une différence significative de performance globale entre l'approche classique supervisée et l'approche par détection d'anomalies. Le modèle SVM démontre une performance supérieure sur ce jeu de données restreint avec une exactitude de 87 %, contre 79 % pour l'AutoEncodeur. Cette domination du modèle classique s'explique principalement par sa capacité à maximiser la marge de séparation entre les classes en utilisant l'intégralité des étiquettes durant l'entraînement, ce qui lui a permis d'atteindre un rappel parfait de 1.00 pour la classe pathologique. Autrement dit, le SVM a réussi à identifier la totalité des patients atteints de la maladie de Parkinson dans l'échantillon de test.

Cependant, l'examen de la précision révèle une nuance importante en faveur de l'approche axée Deep Learning. L'AutoEncodeur affiche une précision de 0.94 pour la classe malade, supérieure à celle du SVM qui est de 0.85. Cela indique que l'AutoEncoder, bien qu'il manque de sensibilité pour détecter tous les cas (il possède un rappel plutôt faible de 0.59), est extrêmement fiable lorsqu'il identifie une anomalie. Il génère donc moins de fausses alertes que le SVM. Cette caractéristique suggère que l'AutoEncodeur a appris une représentation très stricte de la normalité vocale, mais que la faible quantité de données saines disponibles pour son entraînement a limité sa capacité à généraliser suffisamment pour englober toutes les variations pathologiques. En conclusion, bien que le SVM reste le choix le plus performant pour ce volume de données spécifique, l'approche par AutoEn-

codeur montre un potentiel intéressant pour minimiser les faux positifs dans un contexte de diagnostic assisté.

4 Conclusion

Ce projet avait pour objectif d'évaluer l'apport du Deep Learning dans la détection de la maladie de Parkinson à partir de biomarqueurs vocaux en confrontant une approche classique supervisée par SVM à une méthode de détection d'anomalies par AutoEncodeur. Les résultats ont démontré que si le SVM demeure le modèle le plus performant pour un volume de données restreint, affichant une exactitude de 87 %, l'AutoEncodeur s'est distingué par une précision supérieure de 94 %, prouvant sa fiabilité pour minimiser les faux positifs malgré une sensibilité plus faible. Cette étude met en lumière la difficulté d'appliquer des réseaux de neurones profonds sur de petits jeux de données tabulaires où les algorithmes traditionnels conservent une meilleure capacité de généralisation, tout en validant la pertinence conceptuelle de l'apprentissage de la normalité vocale. Pour dépasser ces limites et exploiter pleinement le potentiel du Deep Learning, les perspectives futures devraient s'orienter vers l'utilisation de bases de données plus conséquentes et, surtout, tester l'apprentissage directement sur des signaux audio bruts ; cette approche permettrait d'utiliser des architectures plus complexes pour extraire des caractéristiques temporelles plus fines que les mesures pré-calculées ne peuvent capturer.