


SYSTÈME DE RECOMMANDATION HYBRIDE AVEC MISTRAL

**Analyse de sentiments et fusion de features sur le dataset
Amazon Beauty**

PRÉSENTÉ PAR :

Zakaria Ettouhami
Bacarie Tchabo



Sommaire

01	Présentation de l'article
02	Présentation du projet
03	Traitement des données
04	Modèle Hyrbide
05	Performance du modèle
06	Approche par diversification
07	Conclusion

01 Presentation de l'article

- **Article** : Enhancing recommender systems with LLM-extracted explicit features
- **Auteurs** : Shuai Zhao, Guoquan Jiang
- **Année** : 2026

Problématique :

- Les modèles classiques exploitent surtout les ratings, mais capturent peu les préférences fines exprimées dans les reviews.
- Les LLM comprennent mieux ces reviews, mais leur utilisation directe en recommandation est trop coûteuse et trop lente pour le temps réel.

Question centrale :

Comment exploiter les LLM pour enrichir la recommandation sans ralentir l'inférence ?

Modèle hybride en deux branches :

1. Branche explicite – Reviews + LLM

- Le LLM extrait hors ligne les aspects et les sentiments.
- Construction de F_u et F_i .

2. Branche collaborative – Ratings + interactions

- Utilise les ratings et les interactions utilisateur-item.
- Apprend les préférences implicites.

Fusion finale

Les deux branches sont combinées pour prédire le rating final, sans utiliser le LLM en ligne.

01 Presentation de l'article

Similarité dans AEFARec :

- L'article ne définit pas une similarité explicite comme le cosinus.
- **La compatibilité user-item est apprise automatiquement :**
 - branche collaborative : embeddings utilisateur/item + FM
 - branche explicite : relation entre F_u et F_i via MLP
- Donc la similarité est présente, mais implicite.

Résultats :

Dataset	MSE	MAE
Digital Music	0.7531	0.6287
Yelp	0.9429	0.7523
Clothing	1.0563	0.7981

Évaluation expérimentale

- **Datasets :** Yelp, Amazon Digital Music, Amazon Clothing.
- **LLM utilisés :** GPT-4o et GLM-4-Flash.
- **Métriques :** MSE et MAE.
- **→ Plus elles sont faibles, meilleure est la prédiction.**

- **k= nombre minimal d'aspects conservés :**

Yelp : 7

Digital Music : 5

Clothing : 6

- **α = poids appris lors de la fusion finale :**

α pondère la branche collaborative ;

$1 - \alpha$ pondère la branche explicite.

Dans l'article, $1 - \alpha < 0.5$, donc le signal collaboratif reste dominant, mais les reviews améliorent la prédiction.


AEFARec-GPT obtient les erreurs MSE/MAE les plus faibles par rapport aux modèles collaboratifs, aux modèles basés sur les reviews et aux modèles LLM-powered comparés dans l'article.

01 Presentation de l'article

Points forts	Limites
Exploitation fine des reviews grâce au LLM	Coût du prétraitement LLM
Amélioration des performances de prédiction (MSE/MAE plus faibles)	Dépendance au LLM utilisé et à la qualité des prompts
Modèle hybride combinant filtrage collaboratif et informations textuelles	Similarité user-item présente mais non explicitée clairement
Inférence rapide car le LLM n'est pas utilisé en ligne	Évaluation surtout basée sur MSE/MAE
Meilleure interprétabilité grâce aux aspects extraits	Peu d'analyse sur les métriques Top-K
Étude expérimentale assez complète : comparaison, ablation, effet de k	La diversification des recommandations n'est pas traitée directement

02 Presentation du Projet

Schéma adapté à notre proposition



Principe principal : système de recommandation hybride basé sur les reviews et le filtrage collaboratif.

03 Traitement des données

Objectif : transformer les reviews textuelles du dataset Amazon Beauty Reviews en features exploitables pour la recommandation.

Présentation du Dataset


Le dataset utilisé est Amazon Beauty Reviews. Il contient des avis clients sur des produits de beauté vendus sur Amazon.

(701528 lignes (reviews) , 10 colonnes)

Reviews $\rightarrow$ Nettoyage $\rightarrow$ Filtrage $\rightarrow$ LLM $\rightarrow$ Aspects + Sentiment Scoring $\rightarrow$ F_u , F_i $\rightarrow$ Dataset enrichi

Nettoyage des données

1. **Suppression des lignes sans rating ou sans text**
2. **Sélection des colonnes utiles**
3. **Création d'un texte complet:**
full_text=title+text
4. **Nettoyage léger du texte**
5. **suppression des reviews trop courtes**



Nombre total de reviews : 701316
Nombre d'utilisateurs uniques : 631809
Nombre de produits uniques : 112554


Filtrage des données

Filtrage appliqué :

$user_id \geq 2 reviews$

$parent_asin \geq 5 reviews$

Résultat après filtrage :



Nombre total de reviews :	86 378
Nombre d'utilisateurs uniques :	43 359
Nombre de produits uniques :	20 728

Le LLM Mistral est utilisé en deux étapes :

Extraction des aspects

- 20 groupes de reviews
- 50 reviews par groupe
- Extraction des aspects candidats avec Mistral
- Sélection finale de 15 aspects:

(scent, texture, moisturization, ease of application, longevity, irritation/allergy, quality, value for money, packaging, cleansing ability, comfort, durability, shade range, effectiveness, safety (non-toxic))


Sentiment Scoring

- Pour chaque aspect :
score $\in [-1,1]$
- score positif : avis favorable
- score négatif : avis défavorable
- null : aspect non mentionné
- Scoring appliqué sur : 5000 reviews

À partir des scores de sentiment, deux vecteurs sont construits :

Construction de F_i

F_i = Profil explicite du produit



Moyenne des sentiments par aspect pour chaque produit.

un produit bien évalué sur un aspect aura : $\text{Aspect} > 0$

Construction de F_u

F_u = profil explicite de l'utilisateur




**Nombre de mentions par aspect pour chaque utilisateur.
(les préférences explicites de l'utilisateur)**

un utilisateur qui parle souvent d'un aspect aura une forte importance sur cet aspect


Fichiers obtenus

sentiment_scores_sample.csv



5 000 reviews scorées

item_explicit_features_Fi.csv




3 873 produits

user_explicit_features_Fu.csv




4 710 utilisateurs

04 Modèle Hybride



Construction: F_i



Construction: F_u

Modèle Hybride (Version Papier)

- Branche FM-- filtrage collaboratif

$$e_u \in \mathbb{R}^d \rightarrow user id$$

$$e_i \in \mathbb{R}^d \rightarrow item id$$


$$y_{FM} = w_0 + \sum_j w_j e_u^{(j)} + \sum_j w_j e_i^{(j)} + \sum_j \sum_l \langle v_j, v_l \rangle e_u^{(j)} e_i^{(l)}$$

- Si l'user aime les produits parfumés (dimension 2 élevée) ET que l'item est parfumé (dimension 2 élevée), cette partie va amplifier le score.
- Apprend les patterns implicites depuis les ratings uniquement sans lire les reviews



- Branche MLP-- features explicites

$$F_u \oplus F_i \longrightarrow \text{Concaténation des deux matrices}$$



- Exploite les features explicites extraites des reviews par Mistral

$$\hat{y} = \alpha \cdot y_{FM} + (1 - \alpha) \cdot y_{MLP}$$

$$\mathcal{L} = \frac{1}{|D|} \sum_{(u,i,r) \in D} (\hat{y}(u,i) - r)^2$$

Modèle Hybride

- Branche FM-- filtrage collaboratif

$$e_u \in \mathbb{R}^d \rightarrow \text{userid}$$

$$e_i \in \mathbb{R}^d \rightarrow \text{itemid}$$

$$y_{\text{FM}} = w_0 + \sum_j w_j e_u^{(j)} + \sum_j w_j e_i^{(j)} + \sum_j \sum_l \langle v_j, v_l \rangle e_u^{(j)} e_i^{(l)}$$

- Apprend les patterns implicites depuis les ratings uniquement sans lire les reviews


- Branche MLP-- features explicites

$$F_u \oplus F_i \longrightarrow \text{Concaténation des deux matrices}$$

$$\cos(F_i, F_u) \longrightarrow \text{l'utilisateur et l'item vont dans la même direction}$$

$$F_i \cdot F_u \longrightarrow \text{l'utilisateur valorise correspond à ce que l'item offre}$$



$$F_u \oplus F_i \oplus (F_u \odot F_i) \oplus \cos(F_u, F_i)$$



$$\hat{y} = \alpha \cdot y_{\text{FM}} + (1 - \alpha) \cdot y_{\text{MLP}}$$

$$\mathcal{L} = \frac{1}{|D|} \sum_{(u,i,r) \in D} (\hat{y}(u,i) - r)^2$$

Modèle Hybride



-Pas de surapprentissage marqué

- Train ↓ et Val ↓ ensemble et se stabilise à la fin

-Le modèle converge

05 Performance du modèle

Quelles sont les métriques d'évaluation ?

$$MSE = \frac{1}{|D|} \sum_{i=1}^{|D|} (y_i - \hat{y}_i)^2$$

$$MAE = \frac{1}{|D|} \sum_{i=1}^{|D|} |y_i - \hat{y}_i|$$

$|D|$: taille du jeu de données

y_i : valeur réelle

$\hat{y}_i$: valeur prédite par le modèle

Means Squared Error

Met en évidence la fiabilité globale du modèle en sanctionnant lourdement les erreurs majeures de prédiction.


Mean Absolute Error

Indique de combien d'étoiles notre modèle se trompe en moyenne lorsqu'il prédit la satisfaction client.

05 Performance du modèle


Ce qui est observé dans l'étude v.s. ce que l'on obtient

Métrique	MAE	MSE	α
AEFARec (version classique)	0.5742	0.6763	0.2429
AEFARec + SR	0.5936	0.7142	0.2424



05 Performance du modèle

Le modèle est-il sensible au nombre d'aspects ?



- $k < 7$: sous-information
- $k \in [8, 9]$: zone optimale
- $k \geq 10$: bruit et redondance

['scent', 'texture', 'moisturization', 'ease of application', 'longevity', 'irritation/allergy', 'quality', 'value for money', 'packaging', 'cleansing ability', 'comfort', 'durability', 'shade range', 'effectiveness', 'safety (non-toxic)']

06 Approche par diversification

$$\text{ScoreFinal}(i) = \lambda \cdot \text{ScorePertinence}(i) - (1 - \lambda) \cdot \text{Similarité}(i, S)$$

Pourquoi ?

Un Top-K peut être pertinent mais trop redondant : produits très proches, mêmes aspects, même usage.

On ajoute donc une étape finale qui conserve la pertinence tout en pénalisant les items trop similaires.



$\lambda = 1$: pertinence seule

$\lambda \downarrow$: diversité $\uparrow$

Similarité via F_i

Le LLM n'est pas relancé : on exploite les vecteurs F_i déjà calculés hors ligne.


Impact du paramètre λ

On mesure le compromis entre le score prédit moyen et la diversité de la liste Top-10.

λ	Score moyen	ILD	Lecture
1.0	5.5492	0.5290	pertinence seule
0.9	5.5487	0.5470	diversification légère
0.7	5.5430	0.5949	meilleur compromis
0.5	5.5251	0.6510	diversification forte
0.3	5.4812	0.6964	score plus sacrifié

$\lambda = 0.7$: diversité clairement supérieure, perte de score quasi nulle

ILD = Intra-List Diversity : plus la valeur est élevée, plus le Top-K est varié.



Exemple de re-ranking

Utilisateur exemple : user_idx = 2051

Sans diversification

$$\lambda = 1.0$$

1. B07DQQW545
2. B01KI73NIK
3. B097HDVDSR
4. B07Y5W7Y1C
5. B077PKGDRX
6. B07W995F7B
7. B00GPDRFPO
8. B074FXYZC
9. B07XDB33MK
10. B09G22586Y

ILD = 0.277

Avec diversification

$$\lambda = 0.7$$

1. B07DQQW545
2. B01KI73NIK
3. B097HDVDSR
4. B077PKGDRX
5. B07Y5W7Y1C
6. B07W995F7B
7. B00GPDRFPO
8. B074FXYZC
9. B07XDB33MK
10. B0046XQ75Y

ILD = 0.297

remplacement
en fin de liste

Lecture

La diversification reste volontairement modérée : les meilleurs produits sont conservés, mais la fin du Top-K devient moins redondante.

**+ 7,2 % d'ILD
sur cet exemple**

Bilan

Points forts

- Pipeline complet jusqu'au Top-K
- Diversification branchée après le modèle
- F_i rend la similarité produit explicite
- λ règle simplement le compromis

Limites

- Dépendance aux reviews et aux prompts
- Échantillon limité par le coût API
- MMR simplifié vs méthode LFP complète
- λ fixé manuellement

Perspectives

- λ adaptatif selon le profil utilisateur
- Explications textuelles par aspect
- Mise à jour incrémentale de F_u / F_i
- Tests sur d'autres catégories Amazon

À retenir : la diversification améliore la qualité de la liste finale sans remettre en cause le modèle AEFARec-SR.

07 CONCLUSION